15장 선형모델 연습

Sangkon Han(sangkon@pusan.ac.kr)

2023-03-30

Contents

캘리포니아 집 값(California Housing Prices)

해당 Competition의 데이터는 1990년 캘리포니아 인구조사 데이터인 캘리포니아 주택 가격(California Housing Prices) 데이터셋을 사용하며, 학습을 통해 주택 가격(median)을 예측하는 문제입니다.

데이터 불러오기

```
housing = read.csv("./data/housing.csv")
head(housing)
```

```
##   longitude latitude housing_median_age total_rooms total_bedrooms population
## 1   -122.23    37.88                41         880            129        322
## 2   -122.22    37.86                21        7099           1106       2401
## 3   -122.24    37.85                52        1467            190        496
## 4   -122.25    37.85                52        1274            235        558
## 5   -122.25    37.85                52        1627            280        565
## 6   -122.25    37.85                52         919            213        413
##   households median_income median_house_value ocean_proximity
## 1        126        8.3252             452600        NEAR BAY
## 2       1138        8.3014             358500        NEAR BAY
## 3        177        7.2574             352100        NEAR BAY
## 4        219        5.6431             341300        NEAR BAY
```

```
## 5        259        3.8462             342200        NEAR BAY
## 6        193        4.0368             269700        NEAR BAY
```

변수 요약 정보 확인

해당 데이터에 대한 정확한 정보를 모른다고 가정했을 때 가장 먼저 확인해야 하는 것은 데이터 자료형과 NA 값 입니다.

```
str(housing)
```

```
## 'data.frame':    20640 obs. of  10 variables:
##  $ longitude         : num  -122 -122 -122 -122 -122 ...
##  $ latitude          : num  37.9 37.9 37.9 37.9 37.9 ...
##  $ housing_median_age: num  41 21 52 52 52 52 52 52 42 52 ...
##  $ total_rooms       : num  880 7099 1467 1274 1627 ...
##  $ total_bedrooms    : num  129 1106 190 235 280 ...
##  $ population        : num  322 2401 496 558 565 ...
##  $ households        : num  126 1138 177 219 259 ...
##  $ median_income     : num  8.33 8.3 7.26 5.64 3.85 ...
##  $ median_house_value: num  452600 358500 352100 341300 342200 ...
##  $ ocean_proximity   : chr  "NEAR BAY" "NEAR BAY" "NEAR BAY" "NEAR BAY" ...
```

기술 통계를 기반으로 한 정보도 함께 보도록 하겠습니다.

```
summary(housing)
```

```
##    longitude         latitude     housing_median_age  total_rooms
##  Min.   :-124.3   Min.   :32.54   Min.   : 1.00      Min.   :    2
##  1st Qu.:-121.8   1st Qu.:33.93   1st Qu.:18.00      1st Qu.: 1448
##  Median :-118.5   Median :34.26   Median :29.00      Median : 2127
##  Mean   :-119.6   Mean   :35.63   Mean   :28.64      Mean   : 2636
##  3rd Qu.:-118.0   3rd Qu.:37.71   3rd Qu.:37.00      3rd Qu.: 3148
##  Max.   :-114.3   Max.   :41.95   Max.   :52.00      Max.   :39320
##
##  total_bedrooms     population      households     median_income
##  Min.   :   1.0   Min.   :    3   Min.   :   1.0   Min.   : 0.4999
##  1st Qu.: 296.0   1st Qu.:  787   1st Qu.: 280.0   1st Qu.: 2.5634
##  Median : 435.0   Median : 1166   Median : 409.0   Median : 3.5348
##  Mean   : 537.9   Mean   : 1425   Mean   : 499.5   Mean   : 3.8707
##  3rd Qu.: 647.0   3rd Qu.: 1725   3rd Qu.: 605.0   3rd Qu.: 4.7432
##  Max.   :6445.0   Max.   :35682   Max.   :6082.0   Max.   :15.0001
##  NA's   :207
##  median_house_value ocean_proximity
##  Min.   : 14999     Length:20640
##  1st Qu.:119600     Class :character
##  Median :179700     Mode  :character
##  Mean   :206856
##  3rd Qu.:264725
##  Max.   :500001
##
```

기술 통계 정보를 기반으로 한 데이터를 통해서 확인할 수 있는 것은 아래와 같습니다.

1. `total_bedrooms`에 있는 207건의 결측값(NA)을 처리해야 합니다.
2. `ocean_proximity`는 `binary column`으로 변환해야 합니다.
3. 집 가격에 영향을 미치는 요소로 간주되는 `total_bedrooms`와 `total_rooms`등은 개별 가치로 파악할 수 있도록 `mean_number_bedrooms` 및 `mean_number_rooms`로 만들어야 됩니다.

캐리포니아 집 값 예측 데이터 구조

- logitude, 경도
- latitude, 위도
- housing_median_age, 주변의 집을 그룹화 했기 때문에 중앙값 사용
- total_rooms, 정체 방 수
- total_bedrooms, 전체 침실 수
- population, 인구
- households, 세대수
- median_income, 소득(중앙값)
- median_house_value, 주택 가격(중앙값)
- ocean_proximity, 해안 근접도

시각화를 통한 데이터 확인

```
colnames(housing)
```

```
##  [1] "longitude"          "latitude"           "housing_median_age"
##  [4] "total_rooms"        "total_bedrooms"     "population"
##  [7] "households"         "median_income"      "median_house_value"
## [10] "ocean_proximity"
```

```
par(mfrow=c(2,5))
```

데이터 전체 분포를 확인하도록 하겠습니다.

```
ggplot(data = melt(housing), mapping = aes(x = value)) +
  geom_histogram(bins = 30) +
  facet_wrap(~variable, scales = 'free_x')
```

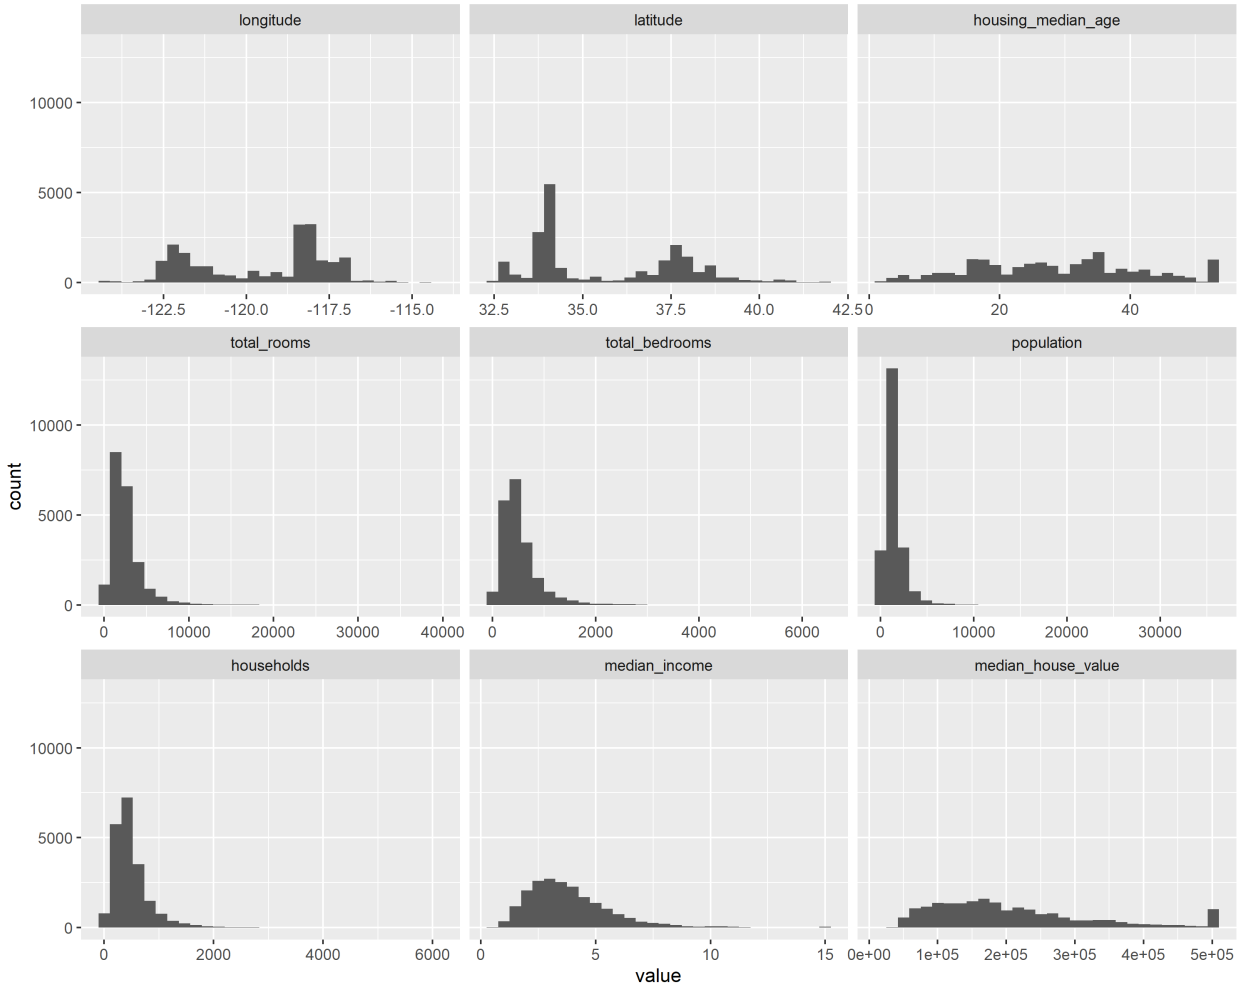

만약 ggplot등과 같은 형태의 데이터를 확인할 수 없다면, 아래와 같이 직접 히스토그램을 작성하셔도 됩니다.

```
par(mfrow = c(3, 3))
hist(housing$longitude, breaks = 30, main = "longitude", border="darkorange", col="dodgerblue")
hist(housing$latitude, breaks = 30, main = "latitude", border="darkorange", col="dodgerblue")
hist(housing$housing_median_age, breaks = 30, main = "housing_median_age", border="darkorange", col="do
hist(housing$total_rooms, breaks = 30, main = "total_rooms", border="darkorange", col="dodgerblue")
hist(housing$total_bedrooms, breaks = 30, main = "total_bedrooms", border="darkorange", col="dodgerblue
hist(housing$population, breaks = 30, main = "population", border="darkorange", col="dodgerblue")
hist(housing$households, breaks = 30, main = "households", border="darkorange", col="dodgerblue")
hist(housing$median_income, breaks = 30, main = "median_income", border="darkorange", col="dodgerblue")
hist(housing$median_house_value, breaks = 30, main = "median_house_value", border="darkorange", col="do
```

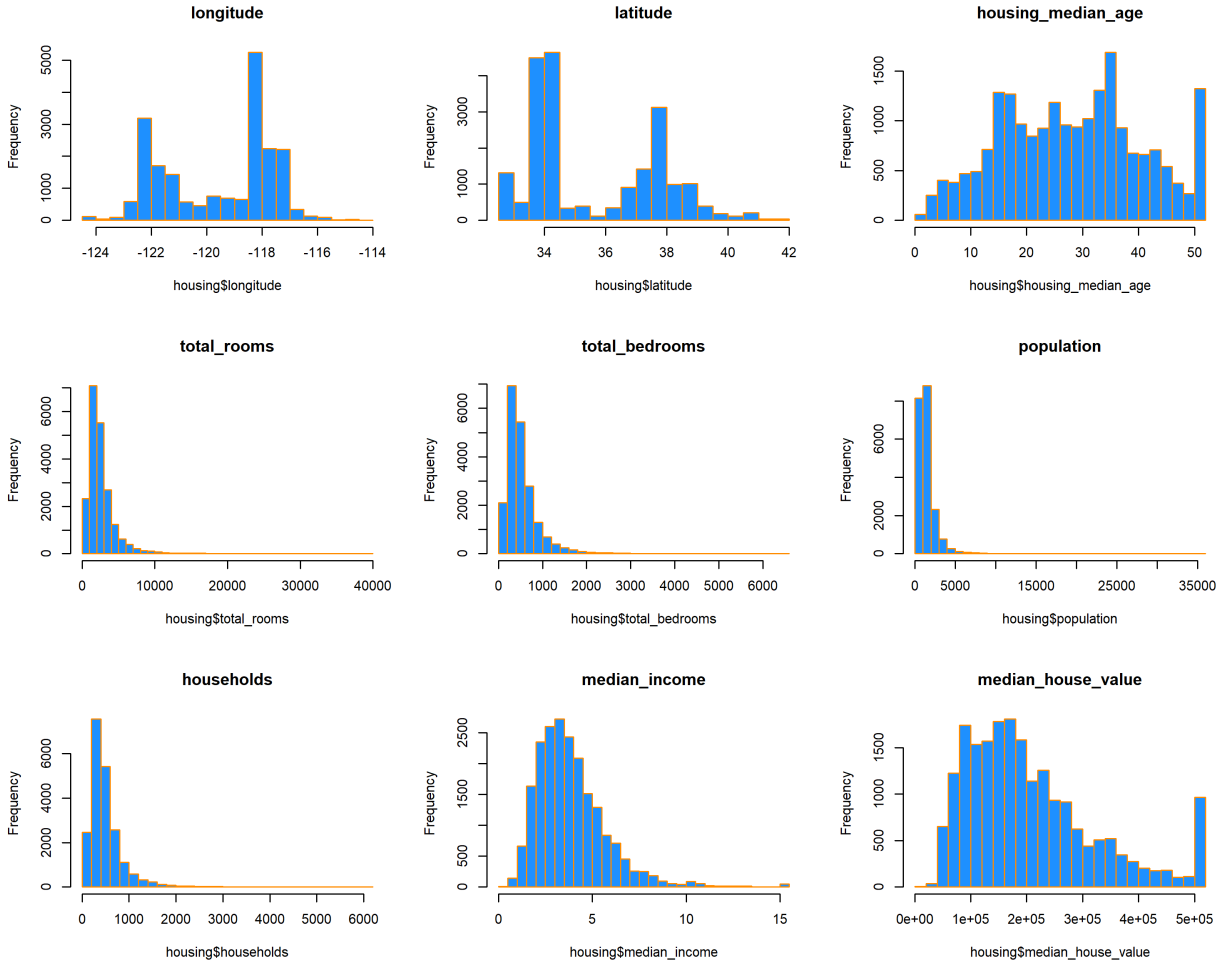


```
plot_map <- ggplot(housing,
                   aes(x = longitude, y = latitude, color = median_house_value,
                       hma = housing_median_age, tr = total_rooms, tb = total_bedrooms,
                       hh = households, mi = median_income)) +
  geom_point(aes(size = population), alpha = 0.4) +
  xlab("Longitude") +
  ylab("Latitude") +
  ggtitle("Data Map - Longtitude vs Latitude and Associated Variables") +
  theme(plot.title = element_text(hjust = 0.5)) +
  scale_color_distiller(palette = "Paired") +
  labs(color = "Median House Value (in $USD)", size = "Population")
plot_map
```

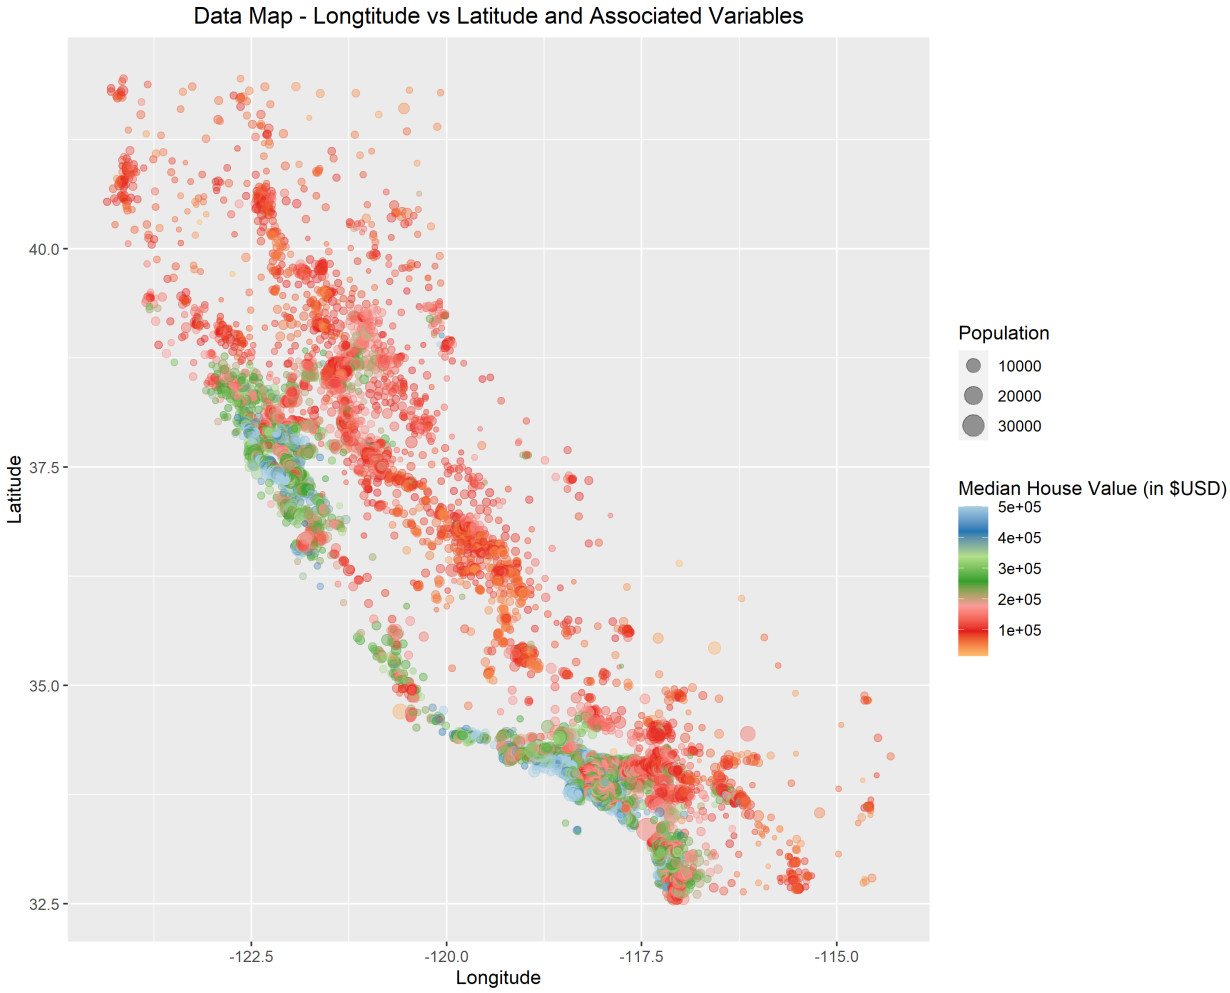

전처리

결측치(NA) 처리

평균에 비해서 극단값에 덜 민감한 중앙값을 사용해서 결측치를 해결하도록 하겠습니다. 그런데 가끔은 정말로 평균이 극단값에 덜 민감한지 확인하거나, 평균이나 중앙값 중 하나를 선택해야 할 때 어떤 것이 좋은 선택인지 궁금할 때가 있습니다. 잠시 확인해보고 넘어가보도록 하겠습니다.

```
bedroom_mean <- mean(housing$total_bedrooms, na.rm=TRUE)
bedroom_median <- median(housing$total_bedrooms, na.rm=TRUE)
ggplot(housing, aes(x = total_bedrooms)) +
  geom_histogram(bins = 40, color = "black", fill = "blue") +
  geom_vline(aes(xintercept = bedroom_mean, color = "Mean"), lwd = 1.5) +
  geom_vline(aes(xintercept = bedroom_median, color = "Median"), lwd = 1.5) +
  xlab("Total Bedrooms") +
  ylab("Frequency") +
  ggtitle("Histogram of Total Bedrooms (noncontinuous variable)") +
  scale_color_manual(name = "Summary Stats", labels = c("Mean", "Median"), values = c("red", "green"))
```

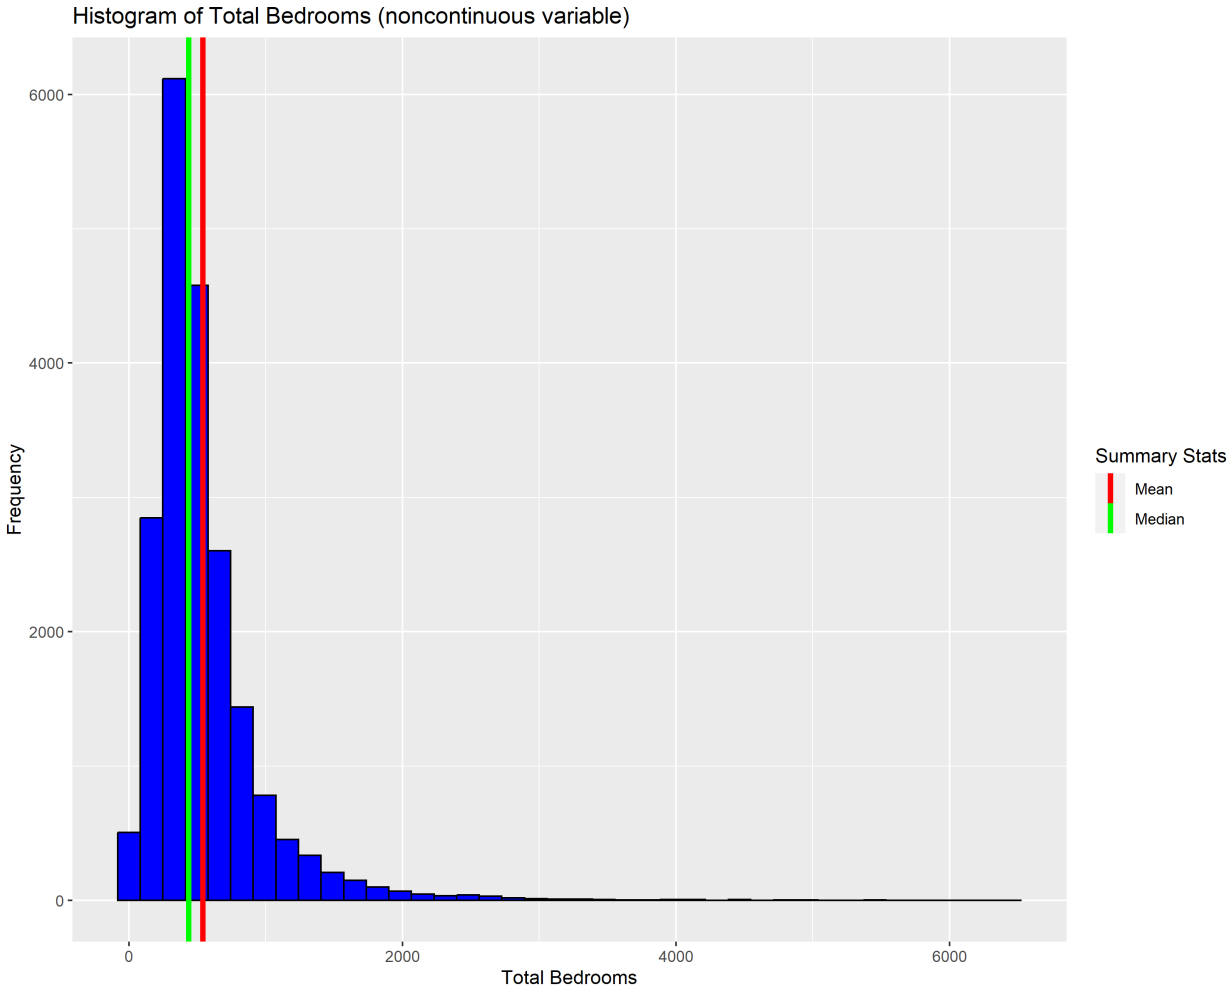

히스토그램에서 데이터 분포를 살펴보면 `total_bedrooms` 변수의 중앙값을 사용하는 것이 더 좋을 듯 합니다. 선택은 각자의 몫이지만, 해당 히스토그램을 통해서 결정에 대한 근거를 찾을 수 있습니다. NA값을 중앙값으로 처리하도록 하겠습니다.

```
housing$total_bedrooms[is.na(housing$total_bedrooms)] <- median(housing$total_bedrooms, na.rm=TRUE)
sum(is.na(housing))
```

```
## [1] 0
```

후처리(Post-Cleaning)

데이터를 정리한 후 데이터셋의 구조를 보면 factor 변수인 `ocean_proximity` 외에도 9개의 numeric 변수가 있음을 알 수 있습니다. 이 중 3개는 연속적(continuous)(`longitude`, `latitude`, `median_income`)이고 6개는 불연속적(discrete)(`housing_median_age`, `total_rooms`, `total_bedrooms`, `population`, `households`, `median_house_value`) 입니다..

```
housing$mean_bedrooms <- housing$total_bedrooms/housing$households
housing$mean_rooms <- housing$total_rooms/housing$households
head(housing)
```

```
##   longitude latitude housing_median_age total_rooms total_bedrooms population
## 1   -122.23    37.88                41         880            129        322
## 2   -122.22    37.86                21        7099           1106       2401
## 3   -122.24    37.85                52        1467            190        496
```

```
## 4   -122.25    37.85                52        1274            235        558
## 5   -122.25    37.85                52        1627            280        565
## 6   -122.25    37.85                52         919            213        413
##   households median_income median_house_value ocean_proximity mean_bedrooms
## 1        126        8.3252             452600        NEAR BAY     1.0238095
## 2       1138        8.3014             358500        NEAR BAY     0.9718805
## 3        177        7.2574             352100        NEAR BAY     1.0734463
## 4        219        5.6431             341300        NEAR BAY     1.0730594
## 5        259        3.8462             342200        NEAR BAY     1.0810811
## 6        193        4.0368             269700        NEAR BAY     1.1036269
##   mean_rooms
## 1   6.984127
## 2   6.238137
## 3   8.288136
## 4   5.817352
## 5   6.281853
## 6   4.761658
```

불필요한 특징 삭제

머신러닝의 학습에 사용되지 않을 불필요한 특징은 삭제하도록 하겠습니다.

```
drops <- c('total_bedrooms', 'total_rooms')
housing <- housing[ , !(names(housing) %in% drops)]
head(housing)
```

```
##   longitude latitude housing_median_age population households median_income
## 1   -122.23    37.88                41        322        126        8.3252
## 2   -122.22    37.86                21       2401       1138        8.3014
## 3   -122.24    37.85                52        496        177        7.2574
## 4   -122.25    37.85                52        558        219        5.6431
## 5   -122.25    37.85                52        565        259        3.8462
## 6   -122.25    37.85                52        413        193        4.0368
##   median_house_value ocean_proximity mean_bedrooms mean_rooms
## 1             452600        NEAR BAY     1.0238095   6.984127
## 2             358500        NEAR BAY     0.9718805   6.238137
## 3             352100        NEAR BAY     1.0734463   8.288136
## 4             341300        NEAR BAY     1.0730594   5.817352
## 5             342200        NEAR BAY     1.0810811   6.281853
## 6             269700        NEAR BAY     1.1036269   4.761658
```

범주형 변수(1)

범주형 변수 처리를 위해서 별도의 데이터 프레임을 생성합니다.

```
categories <- unique(housing$ocean_proximity)
cat_housing <- data.frame(ocean_proximity = housing$ocean_proximity)
head(cat_housing)
```

```
##   ocean_proximity
## 1        NEAR BAY
## 2        NEAR BAY
## 3        NEAR BAY
## 4        NEAR BAY
## 5        NEAR BAY
## 6        NEAR BAY
```

모든 값이 0으로 채워진 데이터 프레임을 생성합니다.

```
for(cat in categories){
  cat_housing[,cat] = rep(0, times= nrow(cat_housing))
}

head(cat_housing)
```

```
##   ocean_proximity NEAR BAY <1H OCEAN INLAND NEAR OCEAN ISLAND
## 1        NEAR BAY        0         0      0          0      0
## 2        NEAR BAY        0         0      0          0      0
## 3        NEAR BAY        0         0      0          0      0
## 4        NEAR BAY        0         0      0          0      0
## 5        NEAR BAY        0         0      0          0      0
## 6        NEAR BAY        0         0      0          0      0
```

필요한 데이터만 1로 업데이트 합니다.

```
for(i in 1:length(cat_housing$ocean_proximity)){
  cat <- as.character(cat_housing$ocean_proximity[i])
  cat_housing[,cat][i] <- 1
}

head(cat_housing)
```

```
##   ocean_proximity NEAR BAY <1H OCEAN INLAND NEAR OCEAN ISLAND
## 1        NEAR BAY        1         0      0          0      0
## 2        NEAR BAY        1         0      0          0      0
## 3        NEAR BAY        1         0      0          0      0
## 4        NEAR BAY        1         0      0          0      0
## 5        NEAR BAY        1         0      0          0      0
## 6        NEAR BAY        1         0      0          0      0
```

기존 특징은 사용하지 않기 때문에 삭제합니다.

```
cat_columns <- names(cat_housing)
keep_columns <- cat_columns[cat_columns != 'ocean_proximity']
cat_housing <- select(cat_housing,one_of(keep_columns))
tail(cat_housing)
```

```
##       NEAR BAY <1H OCEAN INLAND NEAR OCEAN ISLAND
## 20635        0         0      1          0      0
## 20636        0         0      1          0      0
## 20637        0         0      1          0      0
## 20638        0         0      1          0      0
## 20639        0         0      1          0      0
## 20640        0         0      1          0      0
```

수치형 변수 처리

수치의 단위(unit)이 일정하지 않기 때문에 수치형 변수를 일괄로 처리하도록 하겠습니다. 먼저 특징을 확인합니다.

```
colnames(housing)
```

```
##  [1] "longitude"          "latitude"           "housing_median_age"
##  [4] "population"         "households"         "median_income"
##  [7] "median_house_value" "ocean_proximity"    "mean_bedrooms"
```

```
## [10] "mean_rooms"
```

명목형 변수(ocean_proximity)와 예측 변수(median_house_value)는 대상에서 제외하도록 하겠습니다.

```
drops <- c('ocean_proximity','median_house_value')
housing_num <-  housing[ , !(names(housing) %in% drops)]
head(housing_num)
```

```
##   longitude latitude housing_median_age population households median_income
## 1   -122.23    37.88                41        322        126        8.3252
## 2   -122.22    37.86                21       2401       1138        8.3014
## 3   -122.24    37.85                52        496        177        7.2574
## 4   -122.25    37.85                52        558        219        5.6431
## 5   -122.25    37.85                52        565        259        3.8462
## 6   -122.25    37.85                52        413        193        4.0368
##   mean_bedrooms mean_rooms
## 1     1.0238095   6.984127
## 2     0.9718805   6.238137
## 3     1.0734463   8.288136
## 4     1.0730594   5.817352
## 5     1.0810811   6.281853
## 6     1.1036269   4.761658
```

대부분의 데이터는 자신만의 단위(Unit)을 사용합니다. 예를 들어, 한국에서 사용하는 대표적인 단위가 '평수' 입니다. '년', 'km' 등 과 같은 표준적인 단위도 있지만, '마일', '피트'와 같은 특정 문화권에서 사용하는 단위도 있습니다. 그리고 단위에 따른 값의 범위도 꽤 차이가 있습니다. 단위가 다르면 직접적인 비교가 불가능합니다. 그래서 일반적으로 데이터를 정규화 또는 표준화를 진행합니다. 문제는 정규화와 표준화에 대한 이해도가 생각보다 낮다는 점 입니다.

정규화(normalization)는 특성 내에 가장 큰 값은 1로, 가장 작은 값은 0으로 변환합니다. 공식은 아래와 같습니다.

$$\frac{x - x_{min}}{x_{max} - x_{min}}$$

표준화(standardization)는 어떤 특성의 값들이 정규분포, 즉 종모양의 분포를 따른다고 가정하고 값들을 0의 평균, 1의 표준편차를 갖도록 변환해주는 것입니다. 공식은 아래와 같습니다.

$$\frac{x - \mu}{\sigma}(\mu : \text{Éà}, \sigma : \backslash\Gamma\ddot{y}())$$

해당 데이터는 정규화가 아니라 '표준화'를 사용합니다.

```
scaled_housing_num <- scale(housing_num)
head(scaled_housing_num)
```

```
##      longitude latitude housing_median_age population households median_income
## [1,] -1.327803 1.052523          0.9821189 -0.9744050 -0.9770092    2.34470896
## [2,] -1.322812 1.043159         -0.6070042  0.8614180  1.6699206    2.33218146
## [3,] -1.332794 1.038478          1.8561366 -0.8207575 -0.8436165    1.78265622
## [4,] -1.337785 1.038478          1.8561366 -0.7660095 -0.7337637    0.93294491
## [5,] -1.337785 1.038478          1.8561366 -0.7598283 -0.6291419   -0.01288068
## [6,] -1.337785 1.038478          1.8561366 -0.8940491 -0.8017678    0.08744452
##      mean_bedrooms mean_rooms
## [1,]  -0.148510661  0.6285442
## [2,]  -0.248535936  0.3270334
```

```
## [3,]  -0.052900657  1.1555925
## [4,]  -0.053646030  0.1569623
## [5,]  -0.038194658  0.3447024
## [6,]   0.005232996 -0.2697231
```

정리된 데이터 결합

```
cleaned_housing <- cbind(cat_housing, scaled_housing_num, median_house_value=housing$median_house_value)
head(cleaned_housing)
```

```
##   NEAR BAY <1H OCEAN INLAND NEAR OCEAN ISLAND longitude latitude
## 1        1         0      0          0      0 -1.327803 1.052523
## 2        1         0      0          0      0 -1.322812 1.043159
## 3        1         0      0          0      0 -1.332794 1.038478
## 4        1         0      0          0      0 -1.337785 1.038478
## 5        1         0      0          0      0 -1.337785 1.038478
## 6        1         0      0          0      0 -1.337785 1.038478
##   housing_median_age population households median_income mean_bedrooms
## 1          0.9821189 -0.9744050 -0.9770092    2.34470896  -0.148510661
## 2         -0.6070042  0.8614180  1.6699206    2.33218146  -0.248535936
## 3          1.8561366 -0.8207575 -0.8436165    1.78265622  -0.052900657
## 4          1.8561366 -0.7660095 -0.7337637    0.93294491  -0.053646030
## 5          1.8561366 -0.7598283 -0.6291419   -0.01288068  -0.038194658
## 6          1.8561366 -0.8940491 -0.8017678    0.08744452   0.005232996
##   mean_rooms median_house_value
## 1  0.6285442             452600
## 2  0.3270334             358500
## 3  1.1555925             352100
## 4  0.1569623             341300
## 5  0.3447024             342200
## 6 -0.2697231             269700
```

데이터 전/후 처리가 완료되었습니다. 이제 머신러닝을 진행해보도록 하겠습니다.

검증 데이터

이번 단계에서는 전체 데이터에서 학습 데이터(train)와 검증 데이터(test)를 분리합니다. 검증 데이터는 학습된 모델의 평가에만 사용되며, 학습/검증 데이터 분리를 통해 예측 결과의 객관성을 확보할 수 있습니다.

```
set.seed(42)
sample <- sample.int(n = nrow(cleaned_housing), size = floor(.8*nrow(cleaned_housing)), replace = F)
train <- cleaned_housing[sample, ] #just the samples
test  <- cleaned_housing[-sample, ] #everything but the samples
head(train)
```

```
##       NEAR BAY <1H OCEAN INLAND NEAR OCEAN ISLAND  longitude   latitude
## 18753        0         0      1          0      0 -1.4226356  2.3400047
## 9290         1         0      0          0      0 -1.4675563  1.1367943
## 1252         0         0      1          0      0 -1.2978559  1.7220134
## 15506        0         0      0          1      0  1.1528165 -1.1947183
## 8826         0         1      0          0      0  0.6037860 -0.7218613
## 10289        0         1      0          0      0  0.8633277 -0.8154964
##       housing_median_age  population  households median_income mean_bedrooms
## 18753         -0.4480919 -0.25914928 -0.14526644    -1.1726211  0.0008497704
## 9290          -0.3686357  3.29946864  3.61065366    -0.4192346 -0.1380210149
```

```
## 1252           0.5053819 -0.02691193 -0.06156905    -0.6885757  0.1131708564
## 15506         -1.3221096  0.47023494  0.56616133     0.7999851  0.0692684052
## 8826           0.3464696  0.37045235  1.65945840    -0.9738656 -0.1332234247
## 10289         -0.7659165  0.31923651  0.15813658     1.5333170 -0.2562856779
##       mean_rooms median_house_value
## 18753 -0.1479026              80400
## 9290  -0.1533974             118800
## 1252   0.1755923              62700
## 15506  0.6733451             299600
## 8826  -0.9600007             243800
## 10289  0.3635848             264300
```

분리된 데이터가 전체 데이터를 반영하고 있는지 확인합니다.

```
nrow(train) + nrow(test) == nrow(cleaned_housing)
```

```
## [1] TRUE
```

예측 모델 생성 및 평가

단순 선형 모델

간단한 선형 모형 테스트를 위해 아래 3개 변수를 선택하여 분석에 적용합니다. - 소득(중앙값) : median_income - 방 수(평균값) : mean_rooms - 인구 : population

또한, 모델의 과적합(overfit) 문제를 피하기 위해 cv.glm함수를 이용하여 교차 검증(k_fold)를 수행하며, 여기서는 모델 테스트에 전처리된 데이터 자체를 사용합니다.

```
glm_house = glm(median_house_value~median_income+mean_rooms+population, data=cleaned_housing)
k_fold_cv_error = cv.glm(cleaned_housing , glm_house, K=5)
k_fold_cv_error$delta
```

```
## [1] 6936197680 6933908813
```

첫 번째 성분은 예측 오차의 원시 교차 검증 추정치 입니다. 두 번째 구성 요소는 조정된 교차 검증 추정치 입니다.

RMSE(평균 제곱근 오차) 값을 출력합니다. RMSE는 회귀 예측 모델에 대한 두 개의 주요 성과 지표 중 하나입니다. 평균 제곱근 오차는 예측 모델에서 예측한 값과 실제 값 사이의 평균 차이를 측정합니다. 예측 모델이 목표 값(정확도)을 얼마나 잘 예측할 수 있는지 추정합니다. 일반적으로 회귀 모델은 MAE(평균 절대 오차)가 적당하지만, 이상치에 민감한 단점이 있습니다. 해당 데이터는 기본적으로 이상치가 많이 포함된 데이터이기 때문에 MAE가 아닌 RMSE를 사용하도록 하겠씁니다.

```
glm_cv_rmse = sqrt(k_fold_cv_error$delta)[1]
glm_cv_rmse
```

```
## [1] 83283.84
```

glm에서 제공하는 다양한 정보는 아래에서 확인할 수 있습니다.

```
names(glm_house)
```

```
##  [1] "coefficients"      "residuals"         "fitted.values"
##  [4] "effects"           "R"                 "rank"
##  [7] "qr"                "family"            "linear.predictors"
## [10] "deviance"          "aic"               "null.deviance"
## [13] "iter"              "weights"           "prior.weights"
## [16] "df.residual"       "df.null"           "y"
## [19] "converged"         "boundary"          "model"
## [22] "call"              "formula"           "terms"
## [25] "data"              "offset"            "control"
```

```
## [28] "method"            "contrasts"         "xlevels"
```

이중에서 가장 중요한 정보를 제공하는 coefficients를 확인하도록 하겠습니다.

```
glm_house$coefficients
```

```
##   (Intercept) median_income    mean_rooms    population
##    206855.817     82608.959     -9755.442     -3948.293
```

```
## (Intercept) median_income    mean_rooms    population
##  206855.817     82608.959     -9755.442     -3948.293
```

결론

분석을 통해 소득 중앙값(median_income)이 주택 가격(median_house_value)에 가장 큰 영향을 미친다고 판단할 수 있습니다.